

Guion — Parte LLM & Agente

UPV-EARTH · Clasificación de abstracts contra Planetary Boundaries

Duración objetivo: **5:00 min** · Tono natural, hablado en primera persona · Las llaves *[pausa]* marcan momentos para respirar y mirar al público.

1. De qué va mi parte ≈ 0:25

"La parte que me tocó a mí es **la cabeza pensante del sistema**: leer un abstract de la UPV y decir, vale, este paper toca el cambio climático, este otro habla de aerosoles atmosféricos, este otro de biodiversidad, este simplemente no estudia ninguna de las nueve *Planetary Boundaries*. *[pausa]* Y eso lo hicimos **sin tirar de OpenAI ni APIs externas**: todo en local, con Ollama, en una GPU de 24 GB. Tres razones: el dato no sale del laboratorio, los resultados son reproducibles bit a bit, y el coste por inferencia es cero."

2. El stack — qué modelos elegimos y por qué ≈ 0:35

"Probamos tres familias open-source: Llama 3, Gemma 3 y Qwen 2.5. **Qwen ganó** por dos motivos muy prácticos: uno, era el más fiable cuando le pides salida en JSON estricto — los otros se inventaban llaves o metían markdown. Y dos, manejaba español e inglés mezclados sin perder calidad, que es justo el caso del corpus UPV."

"Acabamos con dos modelos: `qwen2.5:14b` como juez principal — unos 9 GB en cuantización Q4 — y `qwen2.5:3b` como extractor rápido para tareas estructuradas. Las dos llamadas siempre con **temperature 0 y JSON-mode**, para que el mismo input dé siempre el mismo output. Si hay aleatoriedad, no hay ciencia."

3. Los prompts — del loro al principio ≈ 1:30

"Voy a contar lo que más aprendí en este proyecto: **el modelo era el mismo en las cuatro versiones, lo que cambiaba era cómo le hablábamos**. Y la diferencia entre la peor y la mejor versión son **13 puntos de accuracy**. Sin tocar pesos, sin fine-tuning."

V1 — FEW-SHOT CONTRASTIVO · "IMITA ESTOS EJEMPLOS"

"Le metíamos diez pares pregunta-respuesta dentro del prompt. **Resultado: efecto loro**. El modelo aprendió a copiar literalmente las frases de los ejemplos en sus razonamientos. Y peor: aprendió una **regla espuria**. PB7 (biodiversidad) recall **cayó del 23 % al 0 %** porque uno de los ejemplos tenía un patrón que el modelo generalizó como 'esto NO es PB7'. Top-1 estricto: **58.5 %**."

V2 — ZERO-SHOT CHAIN-OF-THOUGHT · "RAZONA PASO A PASO"

"Quitamos los ejemplos. En su lugar, un **algoritmo deductivo de cinco pasos** obligatorio:"

YOUR ANALYTICAL ALGORITHM (mandatory deductive checklist)

Step 1 – BIOPHYSICAL EXTRACTION	list every metric quoted from the abstract
Step 2 – CANDIDATE MAPPING	map each metric to the PB it triggers
Step 3 – BACKGROUND vs FOCUS	discard metrics that are only motivation
Step 4 – RANKING	pick primary, secondaries, rejected
Step 5 – JSON OUTPUT	

"Funcionó para que *encontrara* los PBs: el Hit@K subió del 50 % al 72 %. Pero se pasó al lado contrario: **46 % de positivity bias**. En 23 de los 50 papers que el humano había marcado como 'no toca ninguna PB', el modelo se inventaba una. Inutilizable en producción."

V3 — AÑADIMOS UN FILTRO BACKGROUND-VS-FOCUS

"Reforzamos la regla de exclusión: si el paper menciona aerosoles solo en la introducción como contexto, no cuenta. **Bajamos el delirio del 46 al 22 %**. Pero el modelo se acobardó: 29 % de falsos negativos. *Nada* está bien calibrado todavía."

V4_PRINCIPLE — PRINCIPLE-DRIVEN CON ETIQUETAS XML

"La versión que finalmente desplegamos. La idea: **no le des respuestas, dale principios y casos de calibración**. Estructura del prompt:"

```
<system_role> expert scientific evaluator (UPV abstracts vs PB framework)
<task>          identify PBs that the paper MEASURES, MODELS or treats
                  as EXPERIMENTAL FORCING. separate analysis from background.

<instructions>
  1. Identify the *operational object* – the variable being measured.
  2. Match with PB definition.
  3. Apply EXCLUSION RULES (purely social/legal/governance → "None").
  4. Common confusions:
     - Aerosols / PM / AOD belong to PB9, not PB1.
     - Nutrients (N, P) point to PB4.
     - Water-resources management with climate as motivation → PB5.

<reference_framework> 9 PB canonical definitions
<calibration_cases>   5 worked examples (Cases A–E)
<abstract>           the actual paper to classify
<constraints>        JSON only, no markdown, no phrase reuse
```

"Tres detalles que parecen pequeños pero son los que **marcan la diferencia**: primero, los casos de calibración van **antes** del abstract pero el modelo tiene **prohibido reutilizar sus frases**; segundo, las instrucciones explicitan los errores típicos — 'aerosoles son PB9, no PB1' — porque las versiones anteriores los cometían sistemáticamente; tercero, le damos al modelo **permiso para juzgar**: «*your judgment matters more than rigid rule-following*»."

4. La firma de una mejora real

≈ 0:40

"Cuando comparamos las cuatro versiones sobre 147 abstracts validados a mano,

v4_principle gana las seis métricas de acierto:"

Métrica	v1	v2	v3	v4
Top-1 estricto ↑	58.5	63.9	64.6	72.1
Top-1 relajado ↑	62.6	67.3	66.7	76.2
Hit@K ↑	50.5	72.2	61.9	74.2
Jaccard ↑	0.58	0.59	0.60	0.69
True Negative ↑	84.0	54.0	78.0	76.0
Positivity Bias ↓	16.0	46.0	22.0	24.0
Falsos Negativos ↓	41.2	12.4	28.9	14.4

"Lo importante **no es solo que gane**, es que **v4 es la única versión que no compra precisión a costa de cobertura ni al revés**. v1 era rigurosa pero se acobardaba (41 % de falsos negativos); v2 pescaba todo pero deliraba; v3 estaba en tierra de nadie. v4 mantiene 76 % de True Negative y baja los falsos negativos al 14 %. **Ese cuadrante 'no inventa y no se acobarda' es lo que hace que sea desplegable.**"

"Y para descartar suerte: cara a cara contra v3, hay **15 papers donde v4 acierta y v3 falla**, contra solo 4 al revés. La mejora es real."

5. Dónde sigue fallando — la matriz de confusión

≈ 0:35

"Quería enseñar también **dónde no llegamos**, porque es informativo. La confusión cruzada que más se repite, incluso con v4, es esta:"

humano dijo	LLM dijo				leyenda
	PB1	PB4	PB5	PB9	
PB1	.	1	.	3	PB1 = clima
PB7	1	.	1	1	PB4 = nutrientes
PB8	.	1	.	.	PB5 = agua
None	3	1	1	1	PB7 = biodiversidad
					PB9 = aerosoles atmosféricos

"El patrón dominante es **PB1 → PB9**: tres papers de cambio climático que el modelo etiqueta como aerosoles atmosféricos. Es justo el caso que *tenemos avisado en el prompt* ('Aerosols / PM / AOD belong to PB9, not PB1') y aun así sigue colándose **cuando el abstract mide aerosoles para inferir clima**. Es un caso ambiguo de verdad — el modelo elige el objeto medido y el humano la motivación. *[pausa]* Esto nos dice que el siguiente paso no es más prompt-engineering, es **multi-etiqueta**: dejar que el modelo diga 'PB9 primario, PB1 secundario' y evaluar con macro-F1, no con Top-1 estricto."

6. La arquitectura del agente — el truco asimétrico

≈ 1:15

"Sobre el v4_principle montamos un **agente en cascada de cuatro etapas**. La idea: en lugar de pedirle todo a un modelo, descomponemos la tarea en piezas auditables."

① **Extractor**

qwen2.5:3b
JSON estructurado

② **Scorer**

determinista
sin LLM

③ **Juez**

qwen2.5:14b
v4_principle

④ **Crítico**

qwen2.5:14b
asimétrico

① EXTRACTOR CON ANTI-ALUCINACIÓN

"El modelo pequeño extrae cinco campos: especies químicas, métricas físicas, observaciones biológicas, metodología y marco disciplinar. Y aquí hicimos algo defensivo que me parece importante: **un filtro post-hoc que tira cualquier término extraído que no aparezca literalmente en el abstract**. `_grounding_filter()` hace match por substring. Si el modelo se inventa 'CO2' y la palabra no está en el texto, fuera. Cero alucinaciones por construcción."

② SCORER DETERMINISTA — EL ANCLA LÉXICA

"Cuenta coincidencias contra el vocabulario de `pb_reference.csv`. Pondera *core* × 3, *extended* × 2, *applied* × 1. **Sin LLM, coste cero, totalmente reproducible**. Sirve de ancla léxica al juez y, sobre todo, de gatillo para el crítico."

③ JUEZ 14B CON TRES BLOQUES DE CONTEXTO

"El v4_principle pero **enriquecido con las salidas del extractor y del scorer**. Atención al orden: las señales auxiliares van **después del abstract** y con un aviso explícito:"

```
<auxiliary_signals_for_reference_only>
These have known failure modes and are NOT authoritative.
Read the abstract first and form your judgment;
only consult these if you are genuinely uncertain.
NEVER let these signals override what the abstract clearly says.
```

④ CRÍTICO ASIMÉTRICO — LA PIEZA QUE MÁS ME GUSTA

"El crítico es la pieza arquitectónica más interesante. Solo se dispara si el juez dijo *None* y el scorer encontró un PB candidato con $\text{score} \geq 2$. Y aquí está el truco:"

- **Solo puede flipar *None* → PBx**, nunca al revés.
- **Solo puede elegir entre los candidatos del scorer**, no puede inventar PBs.

"Por construcción, no puede degradar una clasificación correcta ni alucinar una etiqueta. **Es un verificador con downside cero**. En validación se invocó 6 veces, hizo 2 rescates limpios (*None* → PB1 y *None* → PB7), y los 4 'mantener *None*' son defendibles. Cero daño."

7. Lo que no funcionó — y por qué lo cuento

≈ 0:25

"Hay una cosa que **no oculto en el report**: la cascada llega al **65.3 %**, *menos* que el v4_principle a pelo (72.1 %). Diagnosticué por qué con un experimento controlado: re-

clasifiqué los 15 papers donde la cascada pierde y encontré que **11 de 15 son selecciones de PB equivocado**, no de None. Las señales auxiliares anclan al juez en el PB equivocado cuando el scorer empata o el extractor sobre-pesa términos secundarios. [pausa] Lo que la cascada sí da, y un solo modelo no, es **auditabilidad y un crítico verificador con cero alucinaciones**. Para deployment con humano en el loop, eso pesa más que dos puntos de accuracy. Gracias."

NOTAS DE ENTREGA

- **Cifras críticas:** 72.1 % v4_principle · 65.3 % cascada · 11 de 15 errores son *wrong-PB* · 3 confusiones PB1 ↔ PB9 son la huella dactilar del modelo.
- **Si vas justo de tiempo:** recorta la sección 5 (matriz de confusión, 35 s). Aporta color pero no es central.
- **"¿Por qué Ollama y no OpenAI?"** Soberanía del dato + reproducibilidad bit a bit (temperature 0 + seed) + coste cero + GPU disponible.
- **"¿Por qué Qwen y no Llama/Gemma?"** Probamos los tres (`runners/{gemma,llama}_zeroshot.py`). Qwen ganó en JSON-mode reliability y en multilingüe (corpus ES+EN).
- **"¿Por qué un cascada si rinde menos?"** Auditabilidad por construcción: cada decisión viene con la traza de extractor + scorer + razonamiento + (si aplica) crítico. Un solo prompt te da un número, no una explicación.
- **"¿Cuánto tarda?"** Pipeline completo sobre 150 papers: **25–35 minutos** en GPU de 24 GB.
- **Siguientes pasos:** macro-F1 multi-etiqueta (resuelve PB1 ↔ PB9), expansión del vocabulario PB (PB8 metales pesados, PB1 paleoclimático), abstención calibrada para *human-in-the-loop*.

Total cronometrado: 0:25 + 0:35 + 1:30 + 0:40 + 0:35 + 1:15 + 0:25 = **5:05 min**. Margen para respirar.