

Análisis de Rendimiento LLM: UPV-EARTH

Evaluación Crítica de Qwen 2.5 (14B)

Zero-Shot vs. Few-Shot en la Clasificación de *Planetary Boundaries*

Autores del Proyecto Original:

Fernando Martínez Gómez, Luis Trigueros Espada, Sergio Ortiz Montesinos,
Sergio Domínguez Miró, Maria Montolio Maximiano, Alba Sanahuja Batalla

Universitat Politècnica de València
Curso 2025-2026

Resumen

Este reporte técnico documenta una anomalía algorítmica observada durante el desarrollo del clasificador de *Planetary Boundaries* (PBs). La transición de una arquitectura de *prompting Zero-Shot* a una *Few-Shot Contrastiva* provocó una degradación generalizada en las métricas del modelo Qwen 2.5 (14B). Analizando el archivo de inferencias (`eval_qwen2.5_14b_FEWSHOT_208.csv`), este documento expone cómo el sobreajuste a los ejemplos introdujo alucinaciones, efecto "loro.^{en} el razonamiento y colapso de categorías.

Índice

1. Resumen Ejecutivo de Métricas	2
2. Autopsia del Few-Shot: Análisis Empírico	2
2.1. El Efecto “Loro” en el Chain-of-Thought	2
2.2. El Colapso de PB7 (Efecto Sombra)	2
2.3. La Trampa Social (Amnesia del Contexto)	2
3. Optimización del Prompt (La Solución Propuesta)	3

1. Resumen Ejecutivo de Métricas

Se analizó un subconjunto de validación compuesto por 150 documentos. Contra la intuición habitual, la inyección de ejemplos (*Few-Shot*) deterioró la capacidad de generalización del modelo.

Cuadro 1: Comparativa General: Zero-Shot vs. Few-Shot (Qwen 2.5 - 14B)

Métrica Macro	Zero-Shot	Few-Shot	Variación
Exact Match (Perfecto)	54.0 %	49.3 %	-4.7 p.p.
Top-1 Accuracy	63.3 %	57.3 %	-6.0 p.p.
Hit@K (Acierto Flexible)	56.6 %	50.5 %	-6.1 p.p.
Jaccard Similarity	0.476	0.407	-0.069
True Negative (None)	84.3 %	82.4 %	-1.9 p.p.
Positivity Bias	15.7 %	17.6 %	+1.9 p.p.

2. Autopsia del Few-Shot: Análisis Empírico

El análisis de la salida bruta del modelo revela que los ejemplos inyectados actuaron como **restricciones de formato y anclas de atención**, alterando la lógica deductiva de Qwen 2.5.

2.1. El Efecto “Loro” en el Chain-of-Thought

Al inspeccionar la columna `llm_reasoning` en el archivo `eval_qwen2.5_14b_FEWSHOT_208.csv`, se detectó que el modelo repetía textualmente frases inducidas por el *prompt*. En las inferencias que resultaron en PB1 (Primario) y PB7 (Secundario), el modelo generó la siguiente justificación:

“Applying the Anti-Overfiltering clause, ecological responses to climate drivers are valid biophysical metrics. Therefore, I must not over-reject.”

El modelo abandonó el análisis semántico del documento real para imitar la retórica exacta del *Example 1* proporcionado en el *prompt*.

2.2. El Colapso de PB7 (Efecto Sombra)

La métrica más alarmante es el *Recall* de **PB7 (Integridad de la Biosfera)**, que cayó del 23 % al **0 %**. El modelo internalizó una regla espuria del *prompt*: «El PB7 es siempre un efecto secundario del PB1; nunca puede ser el problema principal». Cualquier estudio primariamente ecológico fue forzado hacia la categoría climática (PB1).

2.3. La Trampa Social (Amnesia del Contexto)

En el *prompt Few-Shot*, el *Example 3* instruía rechazar documentos puramente sociales/económicos. Como resultado, en **19 de los casos** clasificados como **None** en el CSV, el modelo basó su rechazo afirmando que el texto era «político o económico», utilizando este

comodín incluso en documentos que contenían métricas biofísicas válidas, pero que pertenecían a PBs que el modelo había «olvidado» (como PB4 o PB8) debido a la restricción de atención (*Lost in the Middle*).

3. Optimización del Prompt (La Solución Propuesta)

Para mitigar estos sesgos, se propone abandonar el *Few-Shot* estático y transicionar a una arquitectura **Zero-Shot con Algoritmo de Pensamiento Guiado**.

Nuevo Prompt: Algoritmo Deductivo (Zero-Shot CoT)

YOUR ANALYTICAL ALGORITHM:

Before assigning any PB, you MUST mentally execute this strict checklist:

1. *Biophysical Extraction*: Does the abstract explicitly mention a physical, chemical, or biological metric? If NO, it is a socio-economic paper → Output null.
2. *The Overlap Check*: If the paper is about water (PB5) and nutrients (PB4), which one is the mathematical focus of the study? Select ONLY the dominant boundary.
3. *The Climate Constraint*: Do not default to PB1 just because the word climate appears.

OUTPUT FORMAT:

```
{ "reasoning_process": "Found explicit metric [X]... Rejected PB[Z]  
because...", "primary_pb": "PBX"(or "None") }
```

Esta estructura fuerza al modelo a razonar sobre los datos reales del texto en lugar de hacer *pattern-matching* con ejemplos prefabricados.